ANEXO TÉCNICO

Arquitectura y Diagramas de la ChileCompra Data Platform

Documentación gráfica complementaria
al Trabajo Fin de Máster

Trabajo Fin de Máster

Máster en Ciencia de Datos e Inteligencia Artificial
Universidad Complutense de Madrid

Autor: René Jara Balboa

2026

Figura 1 · Arquitectura Global del Sistema (Capa Física)

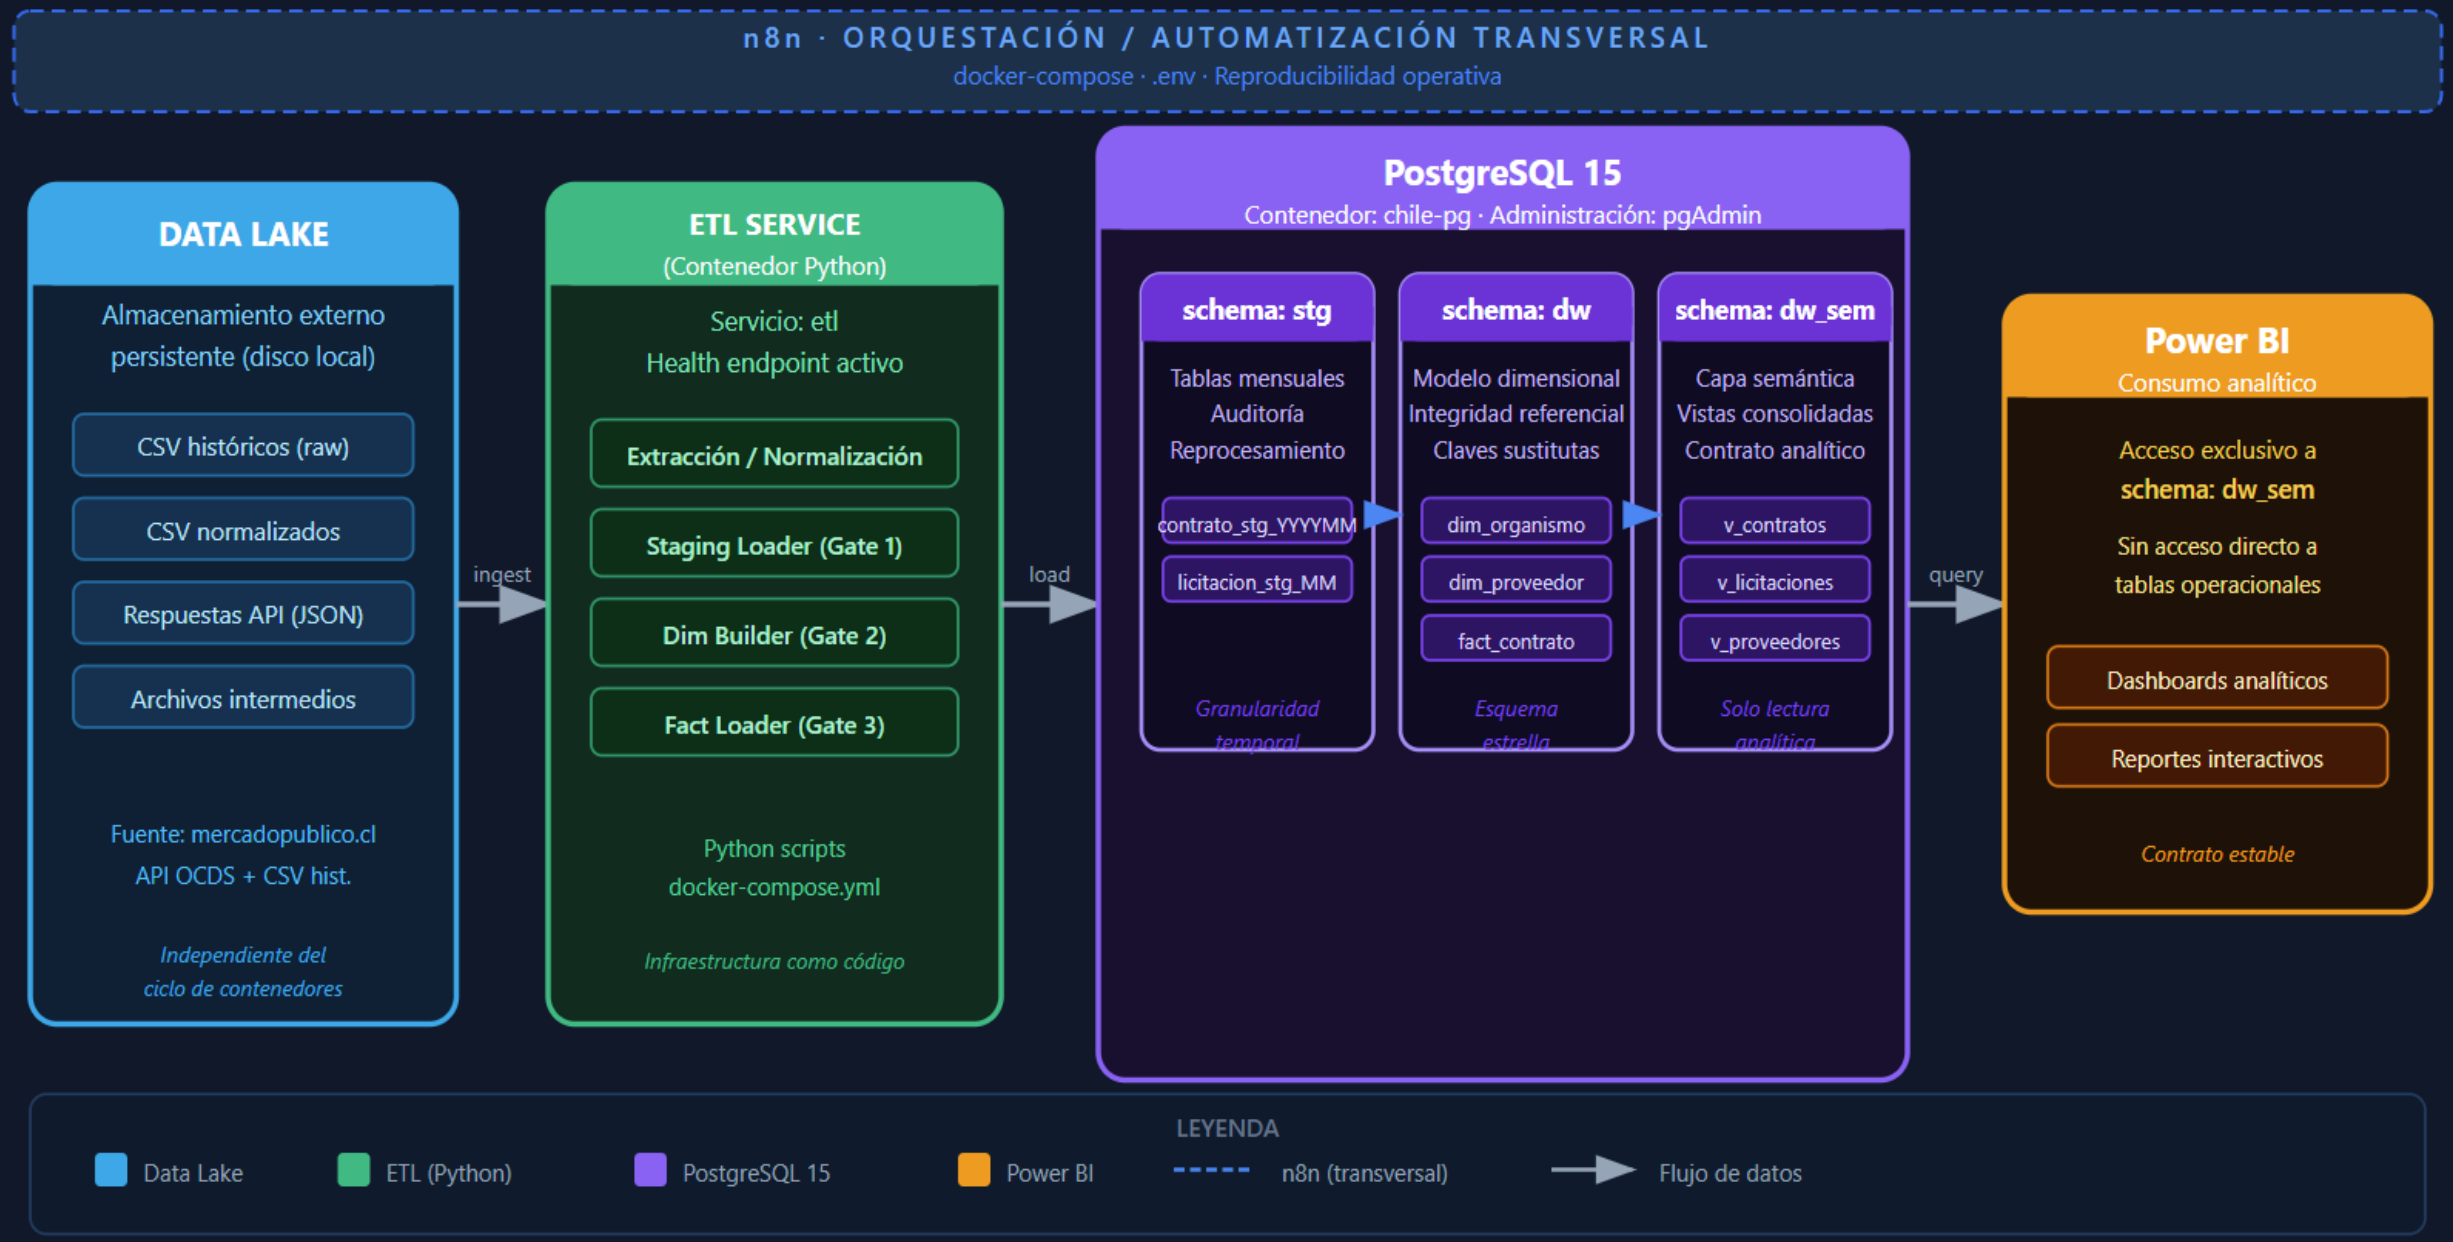

Figura 2· Flujo de Transformación — Capa de Datos

STG → Gate 2 → Gate 3 → DW → dw_sem

FUENTE

CSV históricos
mercadopublico.cl

API OCDS
JSON paginado

Data Lake
Disco externo

Normalización
previa (ETL)

Raw / sin modelo
Trazabilidad temporal

load →

STG · STAGING
schema: stg

Tablas mensuales particionadas
Auditoría y reprocesamiento

- contrato_stg_YYYYMM
- licitacion_stg_MM
- proveedor_stg_MM
- organismo_stg_MM

Columnas raw sin transformar

Preserva granularidad mensual original

Gate 2 →

GATE 2 · DIMS
Construcción dimensional

Genera claves sustitutas (SK)
Resuelve duplicidades
Normaliza entidades

- dim_organismo
- dim_proveedor
- dim_tipo_contrato
- dim_region
- dim_fecha

SK generadas mediante SERIAL / ROW_NUMBER

Gate 3 →

GATE 3 · FACTS
Integración transaccional

Integra dims con hechos
Consolida modelo DW
Integridad referencial (FK)

- fact_contrato
- fact_licitacion
- fact_adjudicacion

Resolución de FK contra dims Gate 2

Métricas: monto, plazo, licitaciones

Esquema estrella (Kimball)

sem. →

DW + dw_sem
Modelo final + Capa semántica

Abstrae complejidad interna
Contrato analítico estable
Desacopla físico / consumo

- v_contratos_detalle
- v_licitaciones_resumen
- v_proveedores_activos
- v_adjudicaciones_region

↓ Power BI
Acceso exclusivo
sin acceso a STG/DW

READ-ONLY · Vistas SQL sin tablas expuestas

---

1. Ingesta — CSV / API → Lake ›
2. Staging — stg.*_YYYYMM ›
3. Gate 2 — dim_* + SK ›
4. Gate 3 — fact_* + FK ›
5. DW — Estrella consolidada ›
6. dw_sem — Vistas analíticas ›
7. Power BI — Consumo exclusivo dw_sem

Figura 3 · Flujo STG → Gate 2 → Gate 3 → DW

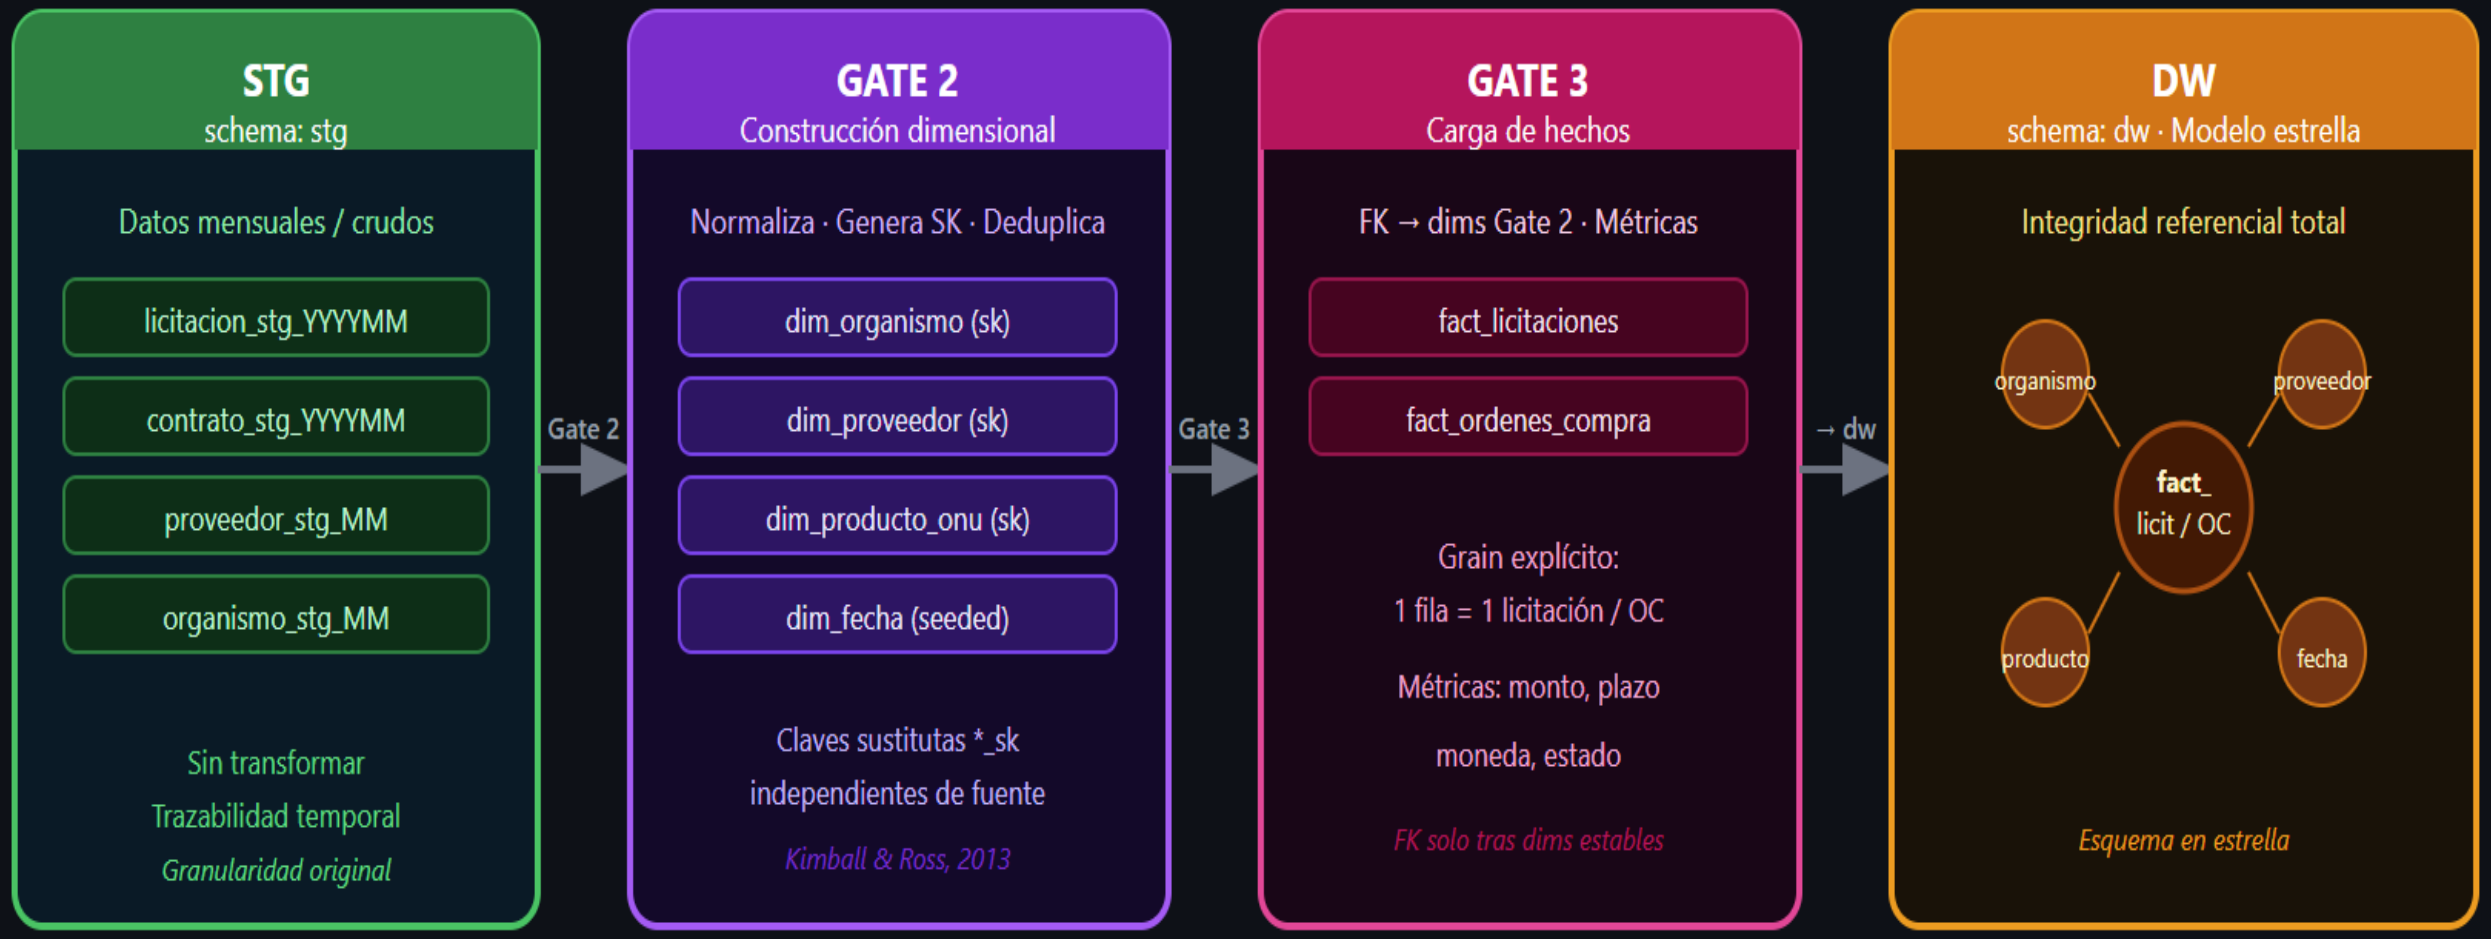

PRINCIPIO CLAVE: Los hechos solo pueden cargarse una vez que su contexto dimensional está estabilizado (Gate 2 precede a Gate 3).

RESULTADO: Modelo dimensional con integridad referencial completa, listo para exposición semántica (dw_sem).

Figura 4 · Diagrama Entidad-Relación — Modelo Dimensional (schema: dw)

Esquema en estrella · PostgreSQL 15 · Kimball & Ross, 2013

Figura 5 · Separación de Schemas: stg / dw / dw_sem

PostgreSQL 15 · Separación estricta de responsabilidades por dominio

schema: stg · RECEPCIÓN MENSUAL

Zona de aterrizaje / buffer temporal

- **licitacion_stg** — _YYYYMM — datos crudos fuente
- **contrato_stg** — _YYYYMM — partición mensual
- **proveedor_stg** — _MM — entidades externas
- **organismo_stg** — _MM — instituciones compradoras

✓ Trazabilidad
✓ Reprocesamiento
✓ Sin transformar

Gate 2 → dims · Gate 3 → facts

schema: dw · MODELO DIMENSIONAL

Esquema en estrella · Integridad referencial

- **dim_organismo** — PK: organismo_sk — SERIAL · NOT NULL
- **dim_proveedor** — PK: proveedor_sk — UNIQUE(rut)
- **dim_producto_onu** — PK: producto_sk — Catálogo ONU
- **dim_fecha** — PK: fecha_sk — seeded script
- **fact_licitaciones** — FK: org_sk · prov_sk — FK: prod_sk · fecha_sk — monto · moneda · estado
- **fact_ordenes_compra** — FK: org_sk · prov_sk — FK: prod_sk · fecha_sk — monto_neto · moneda

Exposición semántica (vistas SQL)

schema: dw_sem · CAPA SEMÁNTICA (CONSUMO)

Contrato analítico · Power BI · READ-ONLY

VISTAS: v_licitaciones_detalle · v_ordenes_compra · v_proveedores_activos · v_adjudicaciones_region · v_recon_global

Desacopla modelo físico de consumo · Power BI no accede directamente a dw ni stg

Figura 6 · Separación Estructural de Capas — Gobierno de Datos

STG → DW → SEM · Fronteras explícitas · Responsabilidades diferenciadas

ZONA 1 · RECEPCIÓN

schema: stg

Tablas mensuales: *_stg_YYYYMM

Datos originales sin transformar

Responsabilidades

- ✓ Preservar granularidad temporal
- ✓ Trazabilidad por período
- ✓ Reprocesamiento selectivo
- ✓ Buffer vs variabilidad fuente

Frontera gobernada

No expone a consumo

Alimenta solo a schema dw

Gate 2
Gate 3

ZONA 2 · MODELADO

schema: dw

Modelo dimensional · Esquema estrella

dim_* + fact_* · FK explícitas

Responsabilidades

- ✓ Integridad referencial (FK)
- ✓ Claves sustitutas *_sk
- ✓ Normalización dimensional
- ✓ Consistencia histórica

Frontera gobernada

No expuesto a BI directamente

Protegido por vistas dw_sem

Vistas
SQL

ZONA 3 · CONSUMO

schema: dw_sem

Capa semántica · Contrato analítico

Vistas v_* estables · READ-ONLY

Responsabilidades

- ✓ Contrato Power BI estable
- ✓ Desacopla físico / consumo
- ✓ Previene ruptura por cambios
- ✓ Exposición controlada

Frontera gobernada

Único punto de acceso BI

Sin acceso a tablas físicas

Principio de gobierno: cada frontera introduce un contrato explícito · Los cambios en una zona no impactan directamente las demás · DAMA International, 2017

Figura 7 · Data Lineage Mensual — Trazabilidad del Dato

Recorrido verificable: archivo origen → vista semántica · Período: 2024-09 → 2025-10

OCT 2024
a
NOV 2025

1. ORIGEN
Archivo fuente

mercadopublico.cl

CSV histórico YYYYMM.csv

API OCDS JSON paginado

Identificador:
periodo_mes

Sin transformar
Trazable a origen

ETL →

2. INBOX
Normalización previa

00_INBOX/

licitaciones.parquet

contratos.parquet

Formato intermedio
Parquet versionado

Persistente en disco
independiente

STG →

3. STG
schema: stg

Partición mensual

licitacion_stg_YYYYMM

contrato_stg_YYYYMM

Auditado por período
Reprocesable

periodo_carga registrado
en cada tabla

DW →

4. DW
schema: dw

Modelo estrella

dim_* + fact_*

FK · PK · NOT NULL

Integridad referencial
Claves sustitutas

Consolidado mensual
acumulativo

SEM →

5. dw_sem
Vista semántica

Contrato analítico

v_licitaciones_detalle

v_ordenes_compra

↓ Power BI
Métricas reproducibles

Rastreable hasta CSV
origen mensual

VERIFICABILIDAD DEL LINEAGE

Toda métrica en Power BI puede rastrearse hacia:

① Período mensual en stg → ② Dimensión en dw.dim_* → ③ Hecho en dw.fact_* → ④ Vista en dw_sem.v_*

Esta propiedad garantiza transparencia institucional en datos de contratación pública (DAMA International, 2017).

Figura 8 · Mecanismos de Control Estructural en el DW

Claves · Restricciones · Validaciones · Calidad no asumida, impuesta (ISO/IEC 25012, 2008)

① Claves Primarias (PK)

SERIAL autogenerado en dim_*
Unicidad garantizada por motor
dim_organismo_sk, proveedor_sk...

Evita duplicados silenciosos

⑤ Restricciones UNIQUE

UNIQUE(rut_proveedor) · UNIQUE(organismo_id) · Sin duplicados por llave natural

② Claves Foráneas (FK)

fact_* referencia dim_*_sk
Prohibe eventos sin contexto
Motor rechaza FK inválidas

Integridad referencial formal

schema: dw

PostgreSQL 15 · Data Warehouse

dim_organismo · dim_proveedor
dim_producto_onu · dim_fecha
fact_licitaciones · fact_ordenes_compra

Esquema estrella · Kimball, 2013
Reconstruible idempotentemente
via db/init scripts versionados

Propiedad: reproducible + auditable

③ Restricciones NOT NULL

Campos críticos no admiten NULL
nombre, rut, fecha_carga...
Previene registros incompletos

Calidad garantizada por esquema

④ Scripts Versionados

db/init/*.sql ordenados
Reconstrucción idempotente
Inicialización automática

Infraestructura como código

⑥ Validaciones Post-carga

Health endpoint ETL · Conteo esperado vs real · Alertas n8n

PRINCIPIO GOBIERNO: La calidad no se asume; se impone mediante reglas estructurales en el motor relacional (ISO

Efecto: control de calidad delegado al RDBMS · Reduce dependencia de validaciones ETL · Degradación silenciosa prevenida

Figura 9 · Arquitectura Contenerizada — Docker Platform

docker-compose.yml · .env centralizado · Infraestructura como código · Fowler, 2006

Reconstrucción tras pruning: docker-compose down -v → docker-compose up → init automático → ETL → DW completo restaurado · Proceso determinístico

Figura 10 · Flujo Mensual Automatizado del Pipeline

n8n orquestador · Período: 2024-09 → 2025-10 · Ejecución reproducible mensual

n8n CRON TRIGGER

Ejecución mensual programada · Período: YYYYMM · Registro de estado por etapa

Workflow orquestado

00 INBOX

Data Lake
00_INBOX/

CSV / JSON
fuente mensual

Validación
presencia archivo

Origen trazable

01 NORMALIZE

ETL Python
/extract endpoint

Limpieza estructural
Tipos + encoding
→ Parquet

Persiste Parquet
en disco externo

Formato intermedio

02 STG LOAD

Gate 1
/staging endpoint

INSERT INTO
*_stg_YYYYMM

Partición mensual

Auditable
Reprocesable

schema: stg

03 GATE 2 · DIMS

/dims endpoint
dim builder

Upsert dim_*
Genera SK

Deduplication

Solo tras STG OK
verificado n8n

schema: dw · dims

04 GATE 3 · FACTS

/facts endpoint
fact loader

INSERT fact_licit
INSERT fact_oc

Resolución FK

Solo tras Gate 2
completado

schema: dw · facts

05 SEM + VALIDATION

Vistas dw_sem
actualizadas automát.

Health check /etl
Conteo esperado
vs real DW

Registro n8n OK/FAIL

→ Power BI disponible
sin afectar consumo

Contrato BI estable

✓ archivo presente | ✓ Parquet generado | ✓ filas stg_YYYYMM | ✓ dims actualizadas | ✓ facts cargados | ✓ validación OK · BI ready

🔴 En caso de fallo en cualquier etapa: n8n detiene el flujo · Registra error · No propaga estado inconsistente al DW · Permite reintento selectivo

PRINCIPIO DataOps: Ejecución secuencial controlada. Cada etapa valida antes de habilitar la siguiente.

Períodos procesados: 2024-09 → 2025-10 (14 meses) · Reproducible sin intervención manual · Auditado en log n8n

La capa BI solo accede a dw_sem actualizado una vez completado el ciclo completo (etapa 05).

Figura 11 · Separación entre Ejecución ETL y Consumo BI

dw_sem como amortiguador estructural · Independencia operación / visualización · ChileCompra Data Platform

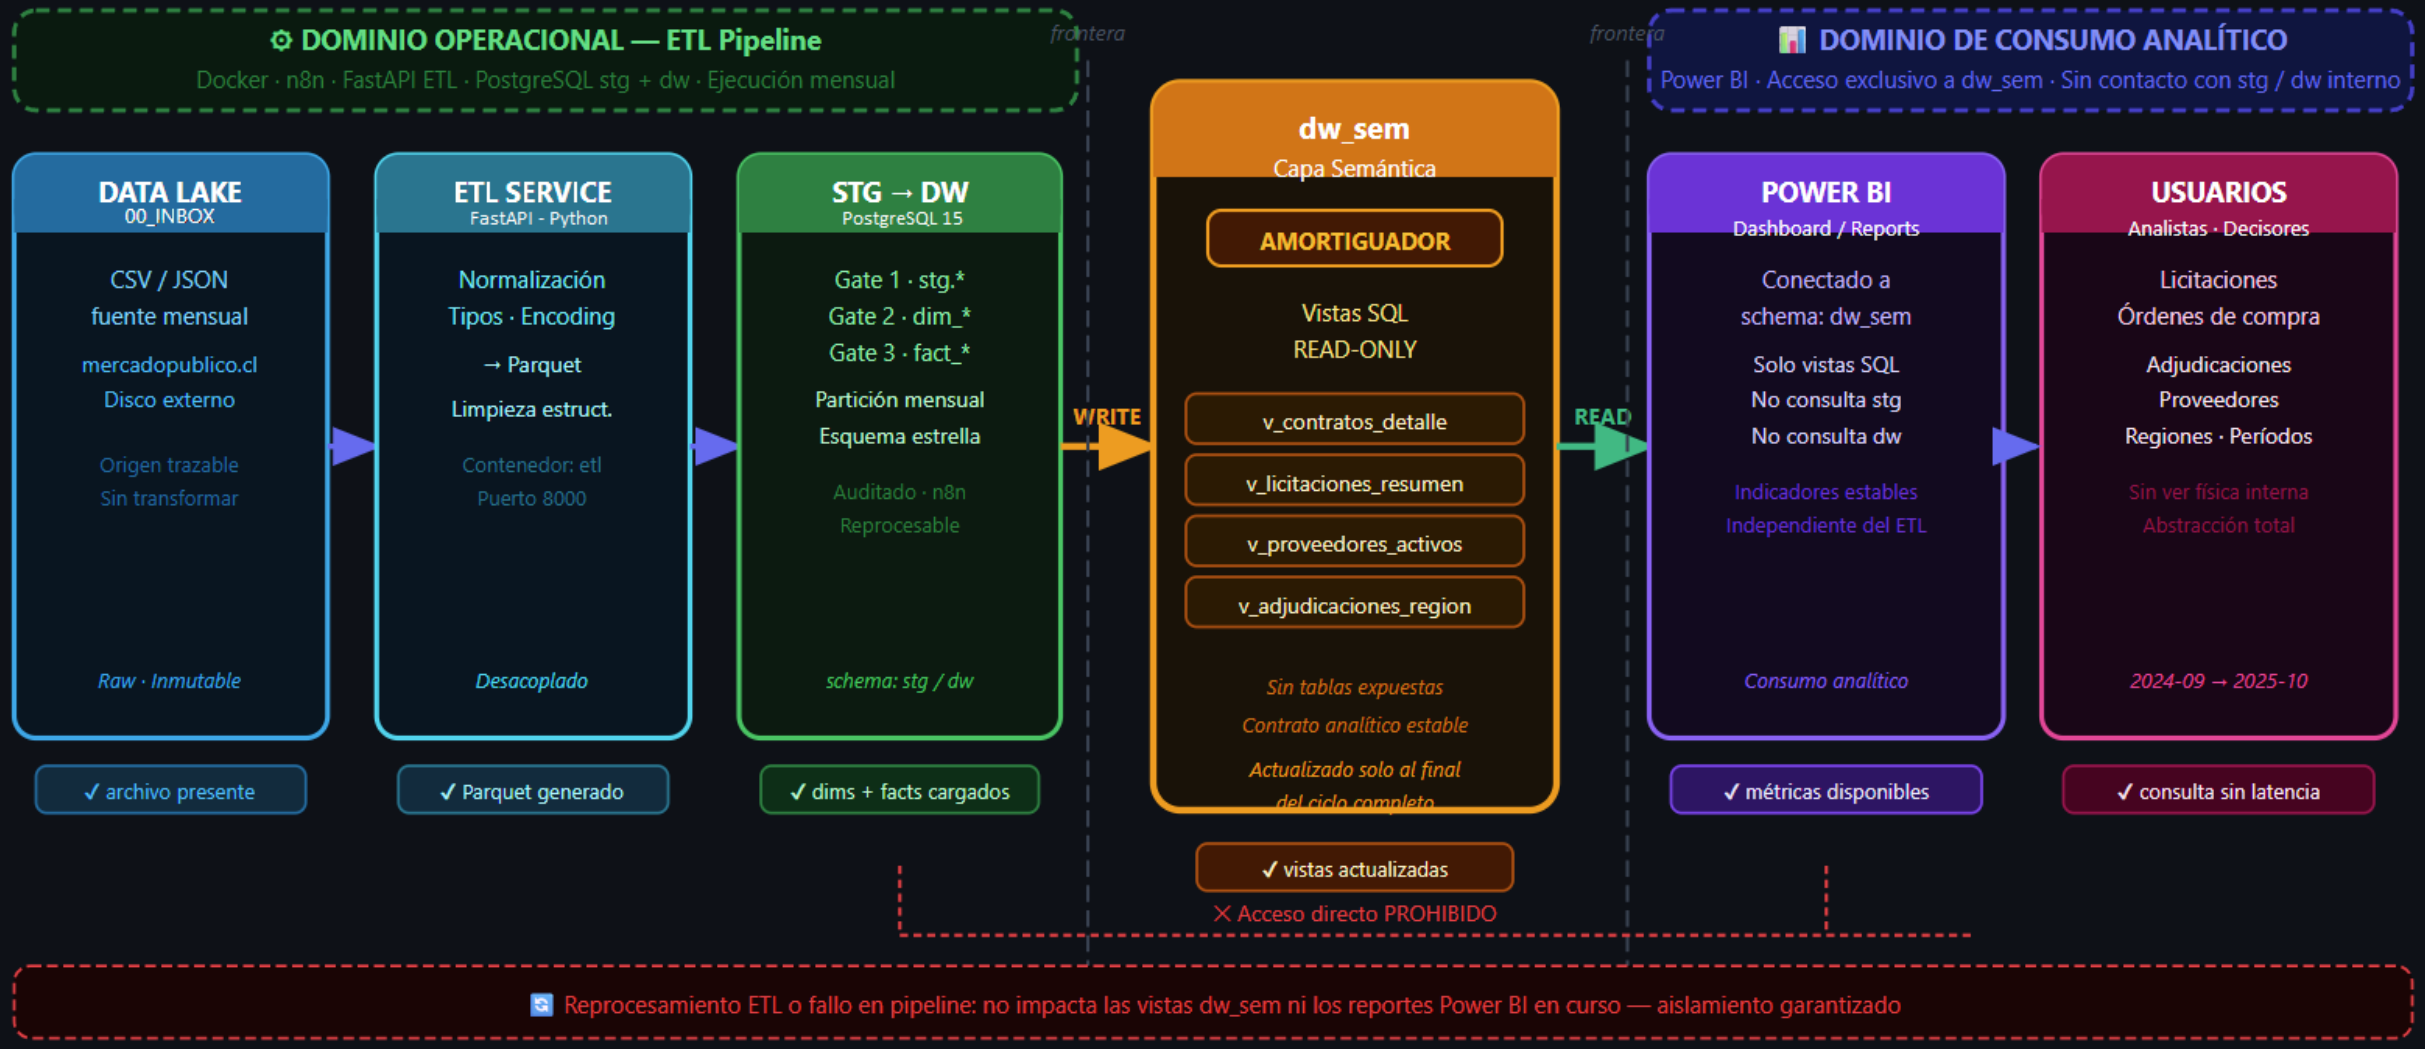

PRINCIPIO de INDEPENDENCIA (cap. 7.6):

La capa semántica actúa como contrato analítico estable: Power BI accede exclusivamente a dw_sem, nunca a stg ni a dw directamente.

Esta separación preserva la estabilidad de indicadores durante reprocesamiento, carga o reconstrucción del pipeline operacional.

Períodos: 2024-09 → 2025-10 · 14 meses procesados · Modelo Kimball & Ross, 2013 · DataOps: Kim et al., 2021